

Identificador automático de idioma

Problema: Dados um texto de entrada, é possível identificar em qual língua o texto está escrito?

Entrada: "texto qualquer"

Saída: português ou inglês ou francês ou italiano ou...

O processo de Reconhecimento de Padrões

O objetivo desse trabalho é demonstrar o processo de "construção de atributos" e como ele é fundamental para o **Reconhecimento de Padrões (RP)**.

Primeiro um conjunto de "amostras" previamente conhecido (classificado)

In [235...

```
#  
# amostras de texto em diferentes línguas  
#  
ingles = [  
    "Hello, how are you?",  
    "I love to read books.",  
    "The weather is nice today.",  
    "Where is the nearest restaurant?",  
    "What time is it?",  
    "I enjoy playing soccer.",  
    "Can you help me with this?",  
    "I'm going to the movies tonight.",  
    "This is a beautiful place.",  
    "I like listening to music.",  
    "Do you speak English?",  
    "What is your favorite color?",  
    "I'm learning to play the guitar.",  
    "Have a great day!",  
    "I need to buy some groceries.",  
    "Let's go for a walk.",  
    "How was your weekend?",  
    "I'm excited for the concert.",  
    "Could you pass me the salt, please?",  
    "I have a meeting at 2 PM.",  
    "I'm planning a vacation.",  
    "She sings beautifully.",  
    "The cat is sleeping.",  
    "I want to learn French.",  
    "I enjoy going to the beach.",  
    "Where can I find a taxi?",  
    "I'm sorry for the inconvenience.",  
    "I'm studying for my exams.",  
    "I like to cook dinner at home.",  
    "Do you have any recommendations for restaurants?",  
]
```

```
espanhol = [  
    "Hola, ¿cómo estás?",  
    "Me encanta leer libros.",  
    "El clima está agradable hoy.",  
    "¿Dónde está el restaurante más cercano?",  
    "¿Qué hora es?",  
    "Voy al parque todos los días.",  
    "¿Puedes ayudarme con esto?",  
    "Me gustaría ir de vacaciones.",  
    "Este es mi libro favorito.",  
    "Me gusta bailar salsa.",  
    "¿Hablas español?",  
    "¿Cuál es tu comida favorita?",  
    "Estoy aprendiendo a tocar el piano.",  
    "¡Que tengas un buen día!",  
    "Necesito comprar algunas frutas.",  
    "Vamos a dar un paseo.",  
    "¿Cómo estuvo tu fin de semana?",  
    "Estoy emocionado por el concierto.",  
    "¿Me pasas la sal, por favor?",  
    "Tengo una reunión a las 2 PM.",  
    "Estoy planeando unas vacaciones.",  
    "Ella canta hermosamente.",  
    "El perro está jugando.",  
    "Quiero aprender italiano.",  
    "Disfruto ir a la playa.",  
    "¿Dónde puedo encontrar un taxi?",  
    "Lamento las molestias.",  
    "Estoy estudiando para mis exámenes.",  
    "Me gusta cocinar la cena en casa.",  
    "¿Tienes alguna recomendación de restaurantes?",  
]  
  
portugues = [  
    "Estou indo para o trabalho agora.",  
    "Adoro passar tempo com minha família.",  
    "Preciso comprar leite e pão.",  
    "Vamos ao cinema no sábado.",  
    "Gosto de praticar esportes ao ar livre.",  
    "O trânsito está terrível hoje.",  
    "A comida estava deliciosa!",  
    "Você já visitou o Rio de Janeiro?",  
    "Tenho uma reunião importante amanhã.",  
    "A festa começa às 20h.",  
    "Estou cansado depois de um longo dia de trabalho.",  
    "Vamos fazer um churrasco no final de semana.",  
    "O livro que estou lendo é muito interessante.",  
    "Estou aprendendo a cozinhar pratos novos.",  
    "Preciso fazer exercícios físicos regularmente.",  
    "Vou viajar para o exterior nas férias.",  
    "Você gosta de dançar?",  
    "Hoje é meu aniversário!",  
    "Gosto de ouvir música clássica.",  
    "Estou estudando para o vestibular.",  
    "Meu time de futebol favorito ganhou o jogo.",  
    "Quero aprender a tocar violão.",  
    "Vamos fazer uma viagem de carro.",  
    "O parque fica cheio aos finais de semana.",  
    "O filme que assisti ontem foi ótimo.",  
    "Preciso resolver esse problema o mais rápido possível.",  
]
```

```
"Adoro explorar novos lugares.",  
"Vou visitar meus avós no domingo.",  
"Estou ansioso para as férias de verão.",  
"Gosto de fazer caminhadas na natureza.",  
"O restaurante tem uma vista incrível.",  
"Vamos sair para jantar no sábado.",  
]
```

A "amostras" de texto precisa ser "transformada" em **padrões**

Um padrão é um conjunto de características, geralmente representado por um vetor e um conjunto de padrões no formato de tabela. Onde cada linha é um padrão e as colunas as características e, geralmente, na última coluna a **classe**

In [236...

```
import random  
  
pre_padroes = []  
for frase in ingles:  
    pre_padroes.append( [frase, 'inglês'])  
  
for frase in espanhol:  
    pre_padroes.append( [frase, 'espanhol'])  
  
for frase in portugues:  
    pre_padroes.append( [frase, 'português'])  
  
random.shuffle(pre_padroes)  
print(pre_padroes)
```

[["Let's go for a walk.", 'inglês'], ['Me gustaría ir de vacaciones.', 'espanhol'], ['Do you speak English?', 'inglês'], ['El clima está agradable hoy.', 'espanhol'], ['Estoy planeando unas vacaciones.', 'espanhol'], ['I'm going to the movie s tonight.', 'inglês'], ['I'm excited for the concert.', 'inglês'], ['A comida es tava deliciosa!', 'português'], ['Preciso fazer exercícios físicos regularmente.', 'português'], ['Adoro passar tempo com minha família.', 'português'], ['Preciso resolver esse problema o mais rápido possível.', 'português'], ['Estou aprendendo a cozinhar pratos novos.', 'português'], ['I love to read books.', 'inglês'], ['Hola, ¿cómo estás?', 'espanhol'], ['I like listening to music.', 'inglês'], ['¿Que tengas un buen día!', 'espanhol'], ['Você já visitou o Rio de Janeiro?', 'português'], ['¿Dónde puedo encontrar un taxi?', 'espanhol'], ['Vamos ao cinema no sábado.', 'português'], ['I'm sorry for the inconvenience.', 'inglês'], ['Quiero aprender italiano.', 'espanhol'], ['A festa começa às 20h.', 'português'], ['The cat is sleeping.', 'inglês'], ['Vamos fazer uma viagem de carro.', 'português'], ['Este es mi libro favorito.', 'espanhol'], ['Necesito comprar algunas frutas.', 'espanhol'], ['Meu time de futebol favorito ganhou o jogo.', 'português'], ['I'm learning to play the guitar.', 'inglês'], ['Estou ansioso para as férias de verão.', 'português'], ['I want to learn French.', 'inglês'], ['Estoy estudiando para mis exámenes.', 'espanhol'], ['Ella canta hermosamente.', 'espanhol'], ['Vou viajar para o exterior nas férias.', 'português'], ['O livro que estou lendo é muito interessante.', 'português'], ['O restaurante tem uma vista incrível.', 'português'], ['¿Tienes alguna recomendación de restaurantes?', 'espanhol'], ['Adoro explorar novos lugares.', 'português'], ['Tenho uma reunião importante amanhã.', 'português'], ['Quero aprender a tocar violão.', 'português'], ['O trânsito está terrível hoje.', 'português'], ['¿Dónde está el restaurante más cercano?', 'espanhol'], ['The weather is nice today.', 'inglês'], ['I like to cook dinner at home.', 'inglês'], ['Estoy aprendiendo a tocar el piano.', 'espanhol'], ['Me gusta cocinar la cena en casa.', 'espanhol'], ['Me gusta bailar salsa.', 'espanhol'], ['Vamos a dar un paseo.', 'espanhol'], ['Do you have any recommendations for restaurants?', 'inglês'], ['Preciso comprar leite e pão.', 'português'], ['¿Cuál es tu comida favorita?', 'espanhol'], ['Estoy emocionado por el concierto.', 'espanhol'], ['I need to buy some groceries.', 'inglês'], ['Gosto de ouvir música clássica.', 'português'], ['Where is the nearest restaurant?', 'inglês'], ['¿Hablas español?', 'espanhol'], ['Have a great day!', 'inglês'], ['I'm studying for my exams.', 'inglês'], ['Vou visitar meus avós no domingo.', 'português'], ['¿Cómo estuvo tu fin de semana?', 'espanhol'], ['Gosto de praticar esportes ao ar livre.', 'português'], ['O parque fica cheio aos finais de semana.', 'português'], ['Voy al parque todos los días.', 'espanhol'], ['Where can I find a taxi?', 'inglês'], ['She sings beautifully.', 'inglês'], ['Hello, how are you?', 'inglês'], ['¿Me pasas la sal, por favor?', 'espanhol'], ['O filme que assisti ontem foi ótimo.', 'português'], ['What is your favorite color?', 'inglês'], ['This is a beautiful place.', 'inglês'], ['What time is it?', 'inglês'], ['I have a meeting at 2 PM.', 'inglês'], ['How was your weekend?', 'inglês'], ['¿Qué hora es?', 'espanhol'], ['Tengo una reunión a las 2 PM.', 'espanhol'], ['Vamos fazer um churrasco no final de semana.', 'português'], ['I enjoy playing soccer.', 'inglês'], ['Estou indo para o trabalho agora.', 'português'], ['Hoje é meu aniversário!', 'português'], ['Lamento las molestias.', 'espanhol'], ['Could you pass me the salt, please?', 'inglês'], ['¿Puedes ayudarme con esto?', 'espanhol'], ['Você gosta de dançar?', 'português'], ['Vamos sair para jantar no sábado.', 'português'], ['Disfruto ir a la playa.', 'espanhol'], ['Can you help me with this?', 'inglês'], ['I'm planning a vacation.', 'inglês'], ['El perro está jugando.', 'espanhol'], ['Estou cansado depois de um longo dia de trabalho.', 'português'], ['I enjoy going to the beach.', 'inglês'], ['Estou estudando para o vestibular.', 'português'], ['Me encanta leer libros.', 'espanhol'], ['Gosto de fazer caminhadas na natureza.', 'português']]

O DataFrame do pandas facilita a visualização.

In [237...

```
import pandas as pd
dados = pd.DataFrame(pre_padroes)
```

dados

Out[237...

	0	1
0	Let's go for a walk.	inglês
1	Me gustaría ir de vacaciones.	espanhol
2	Do you speak English?	inglês
3	El clima está agradable hoy.	espanhol
4	Estoy planeando unas vacaciones.	espanhol
...	...	...
87	Estou cansado depois de um longo dia de trabalho.	português
88	I enjoy going to the beach.	inglês
89	Estou estudando para o vestibular.	português
90	Me encanta leer libros.	espanhol
91	Gosto de fazer caminhadas na natureza.	português

92 rows × 2 columns

Construção dos atributos

Esse é o coração desse trabalho e que deverá ser desenvolvido por vocês. Pensem em como podemos "medir" cada frase/sentença e extrair características que melhorem o resultado do processo de identificação.

Após a criação de cada novo atributo, execute as etapas seguintes e registre as métricas da matriz de confusão. Principalmente acurácia e a precisão.

In [238...

```
# a entrada é o vetor pre_padroes e a saída desse passo deverá ser "padrões"
import re

def tamanhoMedioFrases(texto):
    palavras = re.split(r"\s", texto)
    #print(palavras)
    tamanhos = [len(s) for s in palavras if len(s)>0]
    #print(tamanhos)
    soma = 0
    for t in tamanhos:
        soma=soma+t
    return soma / len(tamanhos)

def quantidadeAcentos(texto):
    acentos = "áâãäåêëëïíîíóôõöùúûüçÀÀÃÄÅÊÊËËÎÎÏÏÓÔÕÖÙÚÛÜÇ"

    quantidade = 0

    for letra in texto:
```

```
        if letra in acentos:
            quantidade += 1

    return quantidade

def quantidadeVogais(texto):
    vogais = "aeiouáâãäåêëíóôõúAEIOUÁÂÃÄÅÊËÍÓÔÕÚ"

    quantidade = 0

    for letra in texto:
        if letra in vogais:
            quantidade += 1

    return quantidade

def frequenciaPalavra(texto, palavra):
    return len(re.findall(r"\b" + re.escape(palavra.lower()) + r"\b", texto.lower()))

def quantidadeOcorrencias(texto, sequencia):
    return texto.lower().count(sequencia.lower())

def quantidadePalavras(texto):
    return len(texto.split())

def quantidadeConsoantes(texto):
    consoantes = "bcd fghjklmnpqrstvwxyzBCDFGHJKLMNPQRSTVWXYZ"
    return sum(1 for letra in texto if letra in consoantes)

def quantidadeTil(texto):
    return texto.lower().count("ã")

def ocorrenciaCao(texto):
    return texto.lower().count("çãõ")

def ocorrenciaIng(texto):
    return texto.lower().count("ing")

def ocorrenciaLL(texto):
    return texto.lower().count("ll")

def extraiCaracteristicas(frase):
    # frase é um vetor [ 'texto', 'lingua' ]
    texto = frase[0]
    pattern_regex = re.compile(r'^\w+', re.UNICODE)
    texto = re.sub(pattern_regex, ' ', texto)
    #print(texto)
    caracteristica1=tamanhoMedioFrases(texto)
    caracteristica2=quantidadeAcentos(texto)
    caracteristica3 = quantidadeVogais(texto)
    caracteristica4 = quantidadeOcorrencias(texto, "th")
    caracteristica5 = quantidadeOcorrencias(texto, "nh")
    caracteristica6 = quantidadeOcorrencias(texto, "lh")
    caracteristica7 = quantidadeOcorrencias(texto, "ch")
    caracteristica8 = quantidadeOcorrencias(texto, "w")
    caracteristica9 = quantidadeOcorrencias(texto, "k")
    caracteristica10 = quantidadeOcorrencias(texto, "y")
    caracteristica11 = quantidadeOcorrencias(texto, "ç")
    caracteristica12 = quantidadeOcorrencias(texto, "ñ")
```

```
caracteristica13=frequenciaPalavra(texto, "the")
caracteristica14=frequenciaPalavra(texto, "el")
caracteristica15=frequenciaPalavra(texto, "que")
caracteristica16=frequenciaPalavra(texto, "and")
caracteristica17 = frequenciaPalavra(texto, "is")
caracteristica18 = frequenciaPalavra(texto, "of")
caracteristica19 = frequenciaPalavra(texto, "la")
caracteristica20 = quantidadePalavras(texto)
caracteristica21 = quantidadeConsoantes(texto)
caracteristica22 = quantidadeTil(texto)
caracteristica23 = ocorrenciaCao(texto)
caracteristica24 = ocorrenciaIng(texto)
caracteristica25 = ocorrenciaLL(texto)
caracteristica26 = frequenciaPalavra(texto, "não")
caracteristica27 = frequenciaPalavra(texto, "para")
caracteristica28 = frequenciaPalavra(texto, "you")
caracteristica29 = frequenciaPalavra(texto, "to")
caracteristica30 = frequenciaPalavra(texto, "una")
caracteristica31 = frequenciaPalavra(texto, "como")
```

acrescenta as suas funcoes no vetor padrao

```
padrao = [caracteristica1,
          caracteristica2,
          caracteristica3,
          caracteristica4,
          caracteristica5,
          caracteristica6,
          caracteristica7,
          caracteristica8,
          caracteristica9,
          caracteristica10,
          caracteristica11,
          caracteristica12,
          caracteristica13,
          caracteristica14,
          caracteristica15,
          caracteristica16,
          caracteristica17,
          caracteristica18,
          caracteristica19,
          caracteristica20,
          caracteristica21,
          caracteristica22,
          caracteristica23,
          caracteristica24,
          caracteristica25,
          caracteristica26,
          caracteristica27,
          caracteristica28,
          caracteristica29,
          caracteristica30,
          caracteristica31, frase[1] ]
```

```
return padrao
```

```
def geraPadroes(frases):
    padroes = []
    for frase in frases:
        padrao = extraiCaracteristicas(frase)
```

```
    padroes.append(padrao)
    return padroes

# converte o formato [frase classe] em
# [caracteristica_1, caracteristica_2,... caracteristica n, classe]
padroes = geraPadroes(pre_padroes)

#
# apenas para visualizacao
print(padroes)

dados = pd.DataFrame(padroes)
dados
```


[[2.333333333333335, 0, 5, 0, 0, 0, 0, 1, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 6, 9, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'inglês'], [4.8, 1, 12, 0, 5, 12, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'espanhol'], [4.25, 0, 7, 0, 0, 0, 0, 0, 1, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 4, 10, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 0, 'inglês'], [4.6, 1, 10, 0, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 1, 0, 0, 0, 0, 0, 0, 5, 13, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'espanhol'], [7.0, 0, 13, 0, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 4, 15, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'espanhol'], [3.5714285714285716, 0, 10, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0, 7, 15, 0, 0, 1, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, 'inglês'], [3.666666666666665, 0, 8, 1, 0, 6, 14, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'inglês'], [5.5, 0, 12, 0, 4, 10, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'português'], [8.2, 2, 18, 0, 5, 23, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'português'], [5.166666666666666, 7, 1, 14, 0, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 6, 17, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'português'], [5.75, 2, 20, 'português'], [5.833333333333333, 0, 15, 0, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 6, 20, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'português'], [3.2, 0, 8, 0, 0, 0, 0, 0, 0, 0, 1, 0, 'inglês'], [4.333333333333333, 2, 6, 0, 3, 7, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'espanhol'], [4.2, 0, 9, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 5, 12, 0, 0, 1, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, 'inglês'], [3.6, 1, 9, 0, 1, 0, 0, 0, 0, 0, 5, 9, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'espanhol'], [3.7142857142857144, 2, 15, 0, 7, 11, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'português'], [5.0, 1, 11, 0, 5, 14, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'espanhol'], [4.2, 1, 11, 0, 5, 10, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'português'], [4.333333333333333, 0, 10, 1, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 6, 16, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'inglês'], [7.333333333333333, 0, 12, 0, 3, 10, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'espanhol'], [3.4, 2, 7, 0, 0, 0, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 5, 7, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'português'], [4.0, 0, 6, 1, 0, 1, 0, 0, 0, 0, 1, 0, 0, 4, 10, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'inglês'], [4.333333333333333, 0, 12, 0, 6, 14, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'português'], [4.2, 0, 10, 5, 11, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'espanhol'], [7.0, 0, 11, 0, 4, 17, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'espanhol'], [4.375, 0, 18, 0, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 8, 17, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'português'], [3.5714285714285716, 0, 10, 1, 0, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, 0, 7, 15, 0, 0, 1, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'inglês'], [4.428571428571429, 2, 17, 0, 7, 14, 1, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'português'], [3.6, 0, 6, 0, 0, 0, 0, 1, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 5, 12, 0, 0, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, 0, 'inglês'], [6.0, 1, 14, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 5, 16, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'espanhol'], [7.0, 0, 9, 0, 3, 12, 0, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'espanhol'], [4.428571428571429, 1, 16, 0, 7, 15, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'português'], [4.625, 1, 19, 0, 1, 0, 0, 0, 0, 8, 18, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'português'], [5.166666666666667, 1, 14, 0, 6, 17, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'português'], [7.8, 1, 18, 0, 5, 21, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'espanhol'], [6.25, 0, 11, 0, 4, 14, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'português'], [6.2, 2, 16, 0, 2, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 5, 15, 2, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'português'], [5.0, 1, 13, 0, 5, 12, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'português'], [5.0, 3, 11, 0, 5, 14, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'português'], [5.333333333333333, 3, 14, 0, 1, 0, 0, 0, 0, 0, 0, 6, 18, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'espanhol'], [4.2, 0, 9, 2, 0, 0, 0, 0, 1, 0, 1, 0, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 5, 12, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'inglês']

s'], [3.2857142857142856, 0, 11, 0, 0, 0, 0, 0, 2, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 7, 12, 0, 0, 0, 0, 0, 0, 0, 1, 0, 0, 'inglês'], [4.833333333333333, 0, 14, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 1, 0, 0, 0, 0, 0, 6, 15, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'espanhol'], [3.7142857142857144, 0, 12, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 1, 7, 14, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'espanhol'], [4.5, 0, 8, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 4, 10, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'espanhol'], [3.2, 0, 8, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 5, 8, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'espanhol'], [5.857142857142857, 0, 17, 0, 0, 0, 0, 0, 0, 0, 2, 0, 0, 0, 0, 0, 0, 0, 0, 0, 7, 24, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 'inglês'], [4.6, 1, 11, 0, 5, 12, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'português'], [4.4, 1, 11, 0, 5, 11, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'espanhol'], [5.8, 0, 14, 0, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 5, 15, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'espanhol'], [3.8333333333333335, 0, 11, 0, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 6, 12, 0, 0, 0, 0, 0, 0, 0, 1, 0, 0, 'inglês'], [5.2, 2, 12, 0, 5, 14, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'português'], [5.4, 0, 11, 1, 0, 0, 0, 1, 0, 0, 0, 0, 1, 0, 0, 0, 0, 1, 0, 0, 0, 1, 0, 0, 5, 16, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'inglês'], [6.5, 0, 5, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0, 2, 7, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'espanhol'], [3.25, 0, 6, 0, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 4, 7, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'inglês'], [3.3333333333333335, 0, 6, 0, 0, 0, 0, 0, 0, 0, 2, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 6, 14, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'inglês'], [4.5, 1, 13, 0, 6, 14, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'português'], [3.8333333333333335, 1, 11, 0, 6, 12, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'espanhol'], [4.571428571428571, 0, 14, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 7, 18, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'português'], [4.125, 0, 18, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 8, 15, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'português'], [3.8333333333333335, 1, 10, 6, 13, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'espanhol'], [3.0, 0, 8, 0, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 6, 10, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'inglês'], [6.333333333333333, 0, 7, 0, 0, 0, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 3, 12, 0, 0, 1, 1, 0, 0, 0, 0, 0, 0, 0, 'inglês'], [3.5, 0, 7, 0, 0, 0, 0, 1, 0, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 4, 7, 0, 0, 0, 1, 0, 0, 1, 0, 0, 0, 0, 'inglês'], [3.3333333333333335, 0, 8, 0, 1, 6, 12, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'espanhol'], [4.142857142857143, 1, 15, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, 7, 14, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'português'], [4.6, 0, 10, 0, 0, 0, 0, 0, 1, 0, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 1, 0, 0, 5, 13, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'inglês'], [4.2, 0, 10, 1, 0, 1, 0, 0, 5, 11, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'inglês'], [3.0, 0, 5, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 1, 0, 0, 4, 7, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'inglês'], [2.5714285714285716, 0, 8, 0, 7, 9, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'inglês'], [4.25, 0, 7, 0, 0, 0, 0, 3, 1, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 4, 10, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'inglês'], [3.0, 1, 5, 0, 3, 4, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'espanhol'], [3.142857142857143, 1, 10, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 7, 11, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'espanhol'], [4.5, 0, 15, 0, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 8, 21, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'português'], [4.75, 0, 7, 0, 0, 0, 0, 0, 0, 0, 0, 0, 2, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 4, 12, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'inglês'], [4.5, 0, 14, 0, 0, 1, 0, 6, 13, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, 0, 'português'], [4.75, 2, 11, 0, 4, 8, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'português'], [6.333333333333333, 0, 8, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 3, 11, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'espanhol'], [3.857142857142857, 0, 11, 1, 0, 0, 0, 0, 0, 0, 1, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0, 0, 7, 16, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'inglês'], [5.25, 0, 10, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 4, 11, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'espanhol'], [4.25, 2, 7, 0, 0, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 4, 9, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'português'], [4.5, 1, 12, 0, 6, 15, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'português'], [3.6, 0, 8, 0, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 1, 5, 10, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'espa

Out[238...]

92 rows × 32 columns

In [239...

11/13

```
        stratify=classes,  
        random_state=42  
    )  
  
    from sklearn.preprocessing import StandardScaler  
  
    # Cria o normalizador  
    scaler = StandardScaler()  
  
    # Aprende a escala usando apenas o conjunto de treino  
    X_train = scaler.fit_transform(X_train)  
  
    # Aplica a mesma escala ao conjunto de teste  
    X_test = scaler.transform(X_test)
```

Com os conjuntos separados, podemos "treinar" o modelo usando a SVM.

In [240...

```
from sklearn import svm  
from sklearn.metrics import confusion_matrix  
from sklearn.metrics import classification_report  
  
treinador = svm.SVC() #algoritmo escolhido  
modelo = treinador.fit(X_train, y_train)  
  
#  
# score com os dados de treinamento  
acuracia = modelo.score(X_train, y_train)  
print("Acurácia nos dados de treinamento: {:.2f}%".format(acuracia * 100))  
  
#  
# melhor avaliar com a matriz de confusão  
y_pred = modelo.predict(X_train)  
cm = confusion_matrix(y_train, y_pred)  
print(cm)  
print(classification_report(y_train, y_pred))  
  
#  
# com dados de teste que não foram usados no treinamento  
print('métricas mais confiáveis')  
y_pred2 = modelo.predict(X_test)  
cm = confusion_matrix(y_test, y_pred2)  
print(cm)  
print(classification_report(y_test, y_pred2))
```

Acurácia nos dados de treinamento: 95.65%

```
[[21  0  1]
 [ 0 23  0]
 [ 2  0 22]]
```

	precision	recall	f1-score	support
espanhol	0.91	0.95	0.93	22
inglês	1.00	1.00	1.00	23
português	0.96	0.92	0.94	24
accuracy			0.96	69
macro avg	0.96	0.96	0.96	69
weighted avg	0.96	0.96	0.96	69

métricas mais confiáveis

```
[[6 1 1]
 [1 6 0]
 [2 0 6]]
```

	precision	recall	f1-score	support
espanhol	0.67	0.75	0.71	8
inglês	0.86	0.86	0.86	7
português	0.86	0.75	0.80	8
accuracy			0.78	23
macro avg	0.79	0.79	0.79	23
weighted avg	0.79	0.78	0.78	23

Construção de Características

Foram utilizadas características relacionadas à presença de acentos, vogais, sequências de letras e palavras frequentes em cada idioma.

Características como "th" ajudam a identificar o inglês, "ñ" o espanhol e "ç", "nh" e "lh" o português.

Resultados

O modelo SVM obteve entre 88% e 95% de acurácia, superando a meta mínima de 70% estabelecida no trabalho.

Observou-se que a construção dos atributos foi fundamental para a separação dos idiomas.