

UNIVERSIDADE FEDERAL DO PARANÁ

PÓS-GRADUAÇÃO EM INTELIGÊNCIA ARTIFICIAL APLICADA

IAA006 - Arquitetura de Dados

Trabalho Técnico / Atividade 01

Integrantes:

Amanda Isabelly Neumann Padilha
Gustavo Gomes Marcondes
Helen Sara Teixeira
Igor Nathan Lobato
Jean Roberto Reinert
Matheus Henrique Miranda

Curitiba 2026

Identificador automático de idioma

Problema: Dados um texto de entrada, é possível identificar em qual língua o texto está escrito?

Entrada: "texto qualquer"

Saída: português ou inglês ou francês ou italiano ou...

O processo de Reconhecimento de Padrões

O objetivo desse trabalho é demonstrar o processo de "construção de atributos" e como ele é fundamental para o **Reconhecimento de Padrões (RP)**.

Primeiro um conjunto de "amostras" previamente conhecido (classificado)

```
In [1]: #
# amostras de texto em diferentes línguas
#
ingles = [
    "Hello, how are you?",
    "I love to read books.",
    "The weather is nice today.",
    "Where is the nearest restaurant?",
    "What time is it?",
    "I enjoy playing soccer.",
    "Can you help me with this?",
    "I'm going to the movies tonight.",
    "This is a beautiful place.",
    "I like listening to music.",
    "Do you speak English?",
    "What is your favorite color?",
    "I'm learning to play the guitar.",
    "Have a great day!",
    "I need to buy some groceries.",
    "Let's go for a walk.",
    "How was your weekend?",
    "I'm excited for the concert.",
    "Could you pass me the salt, please?",
    "I have a meeting at 2 PM.",
    "I'm planning a vacation.",
    "She sings beautifully.",
    "The cat is sleeping.",
    "I want to learn French.",
    "I enjoy going to the beach.",
    "Where can I find a taxi?",
    "I'm sorry for the inconvenience.",
    "I'm studying for my exams.",
    "I like to cook dinner at home.",
    "Do you have any recommendations for restaurants?",
]

espanhol = [
    "Hola, ¿cómo estás?",
    "Me encanta leer libros.",
    "El clima está agradable hoy.",
    "¿Dónde está el restaurante más cercano?",
    "¿Qué hora es?",
    "Voy al parque todos los días.",
    "¿Puedes ayudarme con esto?",
    "Me gustaría ir de vacaciones.",
    "Este es mi libro favorito.",
    "Me gusta bailar salsa.",
    "¿Hablas español?",
    "¿Cuál es tu comida favorita?",
    "Estoy aprendiendo a tocar el piano.",
    "¡Que tengas un buen día!",
]
```

```

"Necesito comprar algunas frutas.",
"Vamos a dar un paseo.",
"¿Cómo estuvo tu fin de semana?",
"Estoy emocionado por el concierto.",
"¿Me pasas la sal, por favor?",
"Tengo una reunión a las 2 PM.",
"Estoy planeando unas vacaciones.",
"Ella canta hermosamente.",
"El perro está jugando.",
"Quiero aprender italiano.",
"Disfruto ir a la playa.",
"¿Dónde puedo encontrar un taxi?",
"Lamento las molestias.",
"Estoy estudiando para mis exámenes.",
"Me gusta cocinar la cena en casa.",
"¿Tienes alguna recomendación de restaurantes?",
]

portugues = [
"Estou indo para o trabalho agora.",
"Adoro passar tempo com minha família.",
"Preciso comprar leite e pão.",
"Vamos ao cinema no sábado.",
"Gosto de praticar esportes ao ar livre.",
"O trânsito está terrível hoje.",
"A comida estava deliciosa!",
"Você já visitou o Rio de Janeiro?",
"Tenho uma reunião importante amanhã.",
"A festa começa às 20h.",
"Estou cansado depois de um longo dia de trabalho.",
"Vamos fazer um churrasco no final de semana.",
"O livro que estou lendo é muito interessante.",
"Estou aprendendo a cozinhar pratos novos.",
"Preciso fazer exercícios físicos regularmente.",
"Vou viajar para o exterior nas férias.",
"Você gosta de dançar?",
"Hoje é meu aniversário!",
"Gosto de ouvir música clássica.",
"Estou estudando para o vestibular.",
"Meu time de futebol favorito ganhou o jogo.",
"Quero aprender a tocar violão.",
"Vamos fazer uma viagem de carro.",
"O parque fica cheio aos finais de semana.",
"O filme que assisti ontem foi ótimo.",
"Preciso resolver esse problema o mais rápido possível.",
"Adoro explorar novos lugares.",
"Vou visitar meus avós no domingo.",
"Estou ansioso para as férias de verão.",
"Gosto de fazer caminhadas na natureza.",
"O restaurante tem uma vista incrível.",
"Vamos sair para jantar no sábado.",
]

```

A "amostras" de texto precisa ser "transformada" em **padrões**

Um padrão é um conjunto de características, geralmente representado por um vetor e um conjunto de padrões no formato de tabela. Onde cada linha é um padrão e as colunas as características e, geralmente, na última coluna a **classe**

```
In [2]: import random

pre_padroes = []
for frase in ingles:
    pre_padroes.append( [frase, 'inglês'])

for frase in espanhol:
    pre_padroes.append( [frase, 'espanhol'])

for frase in portugues:
    pre_padroes.append( [frase, 'português'])

random.shuffle(pre_padroes)
print(pre_padroes)
```

```
[['Quero aprender a tocar violão.', 'português'], ['Can you help me with this?', 'inglês'], ['Preciso fazer exercícios físicos regularmente.', 'português'], ['O trânsito está terrível hoje.', 'português'], ['Do you speak English?', 'inglês'], ['Meu time de futebol favorito ganhou o jogo.', 'português'], ['Me encanta leer libros.', 'espanhol'], ['¿Hablas español?', 'espanhol'], ['Me gusta bailar salsa.', 'espanhol'], ['Vamos a dar un paseo.', 'espanhol'], ['Hello, how are you?', 'inglês'], ['Where can I find a taxi?', 'inglês'], ['¿Dónde puedo encontrar un taxi?', 'espanhol'], ['A festa começa às 20h.', 'português'], ['I need to buy some groceries.', 'inglês'], ['I'm going to the movies tonight.', 'inglês'], ['O livro que estou lendo é muito interessante.', 'português'], ['Gosto de ouvir música clássica.', 'português'], ['El clima está agradable hoy.', 'espanhol'], ['Vamos fazer um churrasco no final de semana.', 'português'], ['Let's go for a walk.', 'inglês'], ['I enjoy going to the beach.', 'inglês'], ['Você já visitou o Rio de Janeiro?', 'português'], ['Preciso comprar leite e pão.', 'português'], ['Have a great day!', 'inglês'], ['Ella canta hermosamente.', 'espanhol'], ['¿Cómo estuvo tu fin de semana?', 'espanhol'], ['I'm learning to play the guitar.', 'inglês'], ['Could you pass me the salt, please?', 'inglês'], ['What time is it?', 'inglês'], ['Hoje é meu aniversário!', 'português'], ['Vou visitar meus avós no domingo.', 'português'], ['I enjoy playing soccer.', 'inglês'], ['O restaurante tem uma vista incrível.', 'português'], ['What is your favorite color?', 'inglês'], ['Disfruto ir a la playa.', 'espanhol'], ['The cat is sleeping.', 'inglês'], ['Estoy planeando unas vacaciones.', 'espanhol'], ['I like listening to music.', 'inglês'], ['Gosto de praticar esportes ao ar livre.', 'português'], ['Estoy aprendiendo a tocar el piano.', 'espanhol'], ['Estou aprendendo a cozinhar pratos novos.', 'português'], ['Me gusta cocinar la cena en casa.', 'espanhol'], ['Vou viajar para o exterior nas férias.', 'português'], ['Vamos fazer uma viagem de carro.', 'português'], ['I'm sorry for the inconvenience.', 'inglês'], ['Vamos sair para jantar no sábado.', 'português'], ['Tenho uma reunião importante amanhã.', 'português'], ['I have a meeting at 2 PM.', 'inglês'], ['Where is the nearest restaurant?', 'inglês'], ['Necesito comprar algunas frutas.', 'espanhol'], ['I love to read books.', 'inglês'], ['Adoro passar tempo com minha família.', 'português'], ['O filme que assisti ontem foi ótimo.', 'português'], ['Estou estudando para o vestibular.', 'português'], ['Hola, ¿cómo estás?', 'espanhol'], ['I'm excited for the concert.', 'inglês'], ['Lamento las molestias.', 'espanhol'], ['O parque fica cheio aos finais de semana.', 'português'], ['I want to learn French.', 'inglês'], ['Gosto de fazer caminhadas na natureza.', 'português'], ['I'm planning a vacation.', 'inglês'], ['I like to cook dinner at home.', 'inglês'], ['I'm studying for my exams.', 'inglês'], ['A comida estava deliciosa!', 'português'], ['How was your weekend?', 'inglês'], ['El perro está jugando.', 'espanhol'], ['¿Qué hora es?', 'espanhol'], ['Estou cansado depois de um longo dia de trabalho.', 'português'], ['Preciso resolver esse problema o mais rápido possível.', 'português'], ['This is a beautiful place.', 'inglês'], ['Estou indo para o trabalho agora.', 'português'], ['¿Dónde está el restaurante más cercano?', 'espanhol'], ['Do you have any recommendations for restaurants?', 'inglês'], ['Me gustaría ir de vacaciones.', 'espanhol'], ['Voy al parque todos los días.', 'espanhol'], ['She sings beautifully.', 'inglês'], ['¿Que tengas un buen día!', 'espanhol'], ['The weather is nice today.', 'inglês'], ['Quiero aprender italiano.', 'espanhol'], ['¿Cuál es tu comida favorita?', 'espanhol'], ['Estoy emocionado por el concierto.', 'espanhol'], ['¿Puedes ayudarme con esto?', 'espanhol'], ['Estou ansioso para as férias de verão.', 'português'], ['Adoro explorar novos lugares.', 'português'], ['¿Tienes alguna recomendación de restaurantes?', 'espanhol'], ['Vamos ao cinema no sábado.', 'português'], ['Tengo una reunión a las 2 PM.', 'espanhol'], ['Estoy estudiando para mis exámenes.', 'espanhol'], ['¿Me pasas la sal, por favor?', 'espanhol'], ['Este es mi libro favorito.', 'espanhol'], ['Você gosta de dançar?', 'português']]
```

O DataFrame do pandas facilita a visualização.

```
In [3]: import pandas as pd
dados = pd.DataFrame(pre_padroes)
```

dados

Out[3]:

0

1

0 Quero aprender a tocar violão. português

1 Can you help me with this? inglês

2 Preciso fazer exercícios físicos regularmente. português

3 O trânsito está terrível hoje. português

4 Do you speak English? inglês

... ..

87 Tengo una reunión a las 2 PM. espanhol

88 Estoy estudiando para mis exámenes. espanhol

89 ¿Me pasas la sal, por favor? espanhol

90 Este es mi libro favorito. espanhol

91 Você gosta de dançar? português

92 rows × 2 columns

Construção dos atributos

Esse é o coração desse trabalho e que deverá ser desenvolvido por vocês. Pensem em como podemos "medir" cada frase/sentença e extrair características que melhorem o resultado do processo de identificação.

Após a criação de cada novo atributo, execute as etapas seguintes e registre as métricas da matriz de confusão. Principalmente acurácia e a precisão.

```
In [4]: # a entrada e o vetor pre_padroes e a saída desse passo deverá ser "padrões"
import re
```

```
def tamanhoMedioFrases(texto):  
    palavras = re.split(r"\s", texto)  
    #print(palavras)  
    tamanhos = [len(s) for s in palavras if len(s)>0]  
    #print(tamanhos)  
    soma = 0  
    for t in tamanhos:  
        soma=soma+t  
    return soma / len(tamanhos)  
  
def quantidadeAcentos(texto):  
    acentos = "áàãäåëèéíîïïóôõöùúûüçÁÂÃÄÅÊËÈÉÍÎÏÎÓÔÕÖÙÚÛÜÇ"  
    quantidade = 0  
    for letra in texto:
```

```

        if letra in acentos:
            quantidade += 1

    return quantidade

def quantidadeVogais(texto):
    vogais = "aeiouáâãäåêëíóôõúAEIOUÁÂÃÄÅÊËÍÓÔÕÚ"

    quantidade = 0

    for letra in texto:
        if letra in vogais:
            quantidade += 1

    return quantidade

def frequenciaPalavra(texto, palavra):
    return len(re.findall(r"\b" + re.escape(palavra.lower()) + r"\b", texto.lower()))

def quantidadeOcorrencias(texto, sequencia):
    return texto.lower().count(sequencia.lower())

def quantidadePalavras(texto):
    return len(texto.split())

def quantidadeConsoantes(texto):
    consoantes = "bcd fghjklmnpqrstvwxyzBCDFGHJKLMNPQRSTVWXYZ"
    return sum(1 for letra in texto if letra in consoantes)

def quantidadeTil(texto):
    return texto.lower().count("ã")

def ocorrenciaCao(texto):
    return texto.lower().count("cão")

def ocorrenciaIng(texto):
    return texto.lower().count("ing")

def ocorrenciaLL(texto):
    return texto.lower().count("ll")

def extraiCaracteristicas(frase):
    # frase é um vetor [ 'texto', 'lingua' ]
    texto = frase[0]
    pattern_regex = re.compile(r'^[w+]', re.UNICODE)
    texto = re.sub(pattern_regex, ' ', texto)
    #print(texto)
    caracteristica1=tamanhoMedioFrases(texto)
    caracteristica2=quantidadeAcentos(texto)
    caracteristica3 = quantidadeVogais(texto)
    caracteristica4 = quantidadeOcorrencias(texto, "th")
    caracteristica5 = quantidadeOcorrencias(texto, "nh")
    caracteristica6 = quantidadeOcorrencias(texto, "lh")
    caracteristica7 = quantidadeOcorrencias(texto, "ch")
    caracteristica8 = quantidadeOcorrencias(texto, "w")
    caracteristica9 = quantidadeOcorrencias(texto, "k")
    caracteristica10 = quantidadeOcorrencias(texto, "y")
    caracteristica11 = quantidadeOcorrencias(texto, "ç")
    caracteristica12 = quantidadeOcorrencias(texto, "ñ")

```

```
caracteristica13=frequenciaPalavra(texto, "the")
caracteristica14=frequenciaPalavra(texto, "el")
caracteristica15=frequenciaPalavra(texto, "que")
caracteristica16=frequenciaPalavra(texto, "and")
caracteristica17 = frequenciaPalavra(texto, "is")
caracteristica18 = frequenciaPalavra(texto, "of")
caracteristica19 = frequenciaPalavra(texto, "la")
caracteristica20 = quantidadePalavras(texto)
caracteristica21 = quantidadeConsoantes(texto)
caracteristica22 = quantidadeTil(texto)
caracteristica23 = ocorrenciaCao(texto)
caracteristica24 = ocorrenciaIng(texto)
caracteristica25 = ocorrenciaLL(texto)
caracteristica26 = frequenciaPalavra(texto, "não")
caracteristica27 = frequenciaPalavra(texto, "para")
caracteristica28 = frequenciaPalavra(texto, "you")
caracteristica29 = frequenciaPalavra(texto, "to")
caracteristica30 = frequenciaPalavra(texto, "una")
caracteristica31 = frequenciaPalavra(texto, "como")

# acrescente as suas funcoes no vetor padrao
padrao = [caracteristica1,
          caracteristica2,
          caracteristica3,
          caracteristica4,
          caracteristica5,
          caracteristica6,
          caracteristica7,
          caracteristica8,
          caracteristica9,
          caracteristica10,
          caracteristica11,
          caracteristica12,
          caracteristica13,
          caracteristica14,
          caracteristica15,
          caracteristica16,
          caracteristica17,
          caracteristica18,
          caracteristica19,
          caracteristica20,
          caracteristica21,
          caracteristica22,
          caracteristica23,
          caracteristica24,
          caracteristica25,
          caracteristica26,
          caracteristica27,
          caracteristica28,
          caracteristica29,
          caracteristica30,
          caracteristica31, frase[1] ]

return padrao

def geraPadroes(frases):
    padroes = []
    for frase in frases:
        padrao = extraiCaracteristicas(frase)
```



```
        padroes.append(padrao)
    return padroes

# converte o formato [frase classe] em
# [caracteristica_1, caracteristica_2,... caracteristica n, classe]
padroes = geraPadroes(pre_padroes)

#
# apenas para visualizacao
print(padroes)

dados = pd.DataFrame(padroes)
dados
```

```

[[5.0, 1, 13, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 5, 12, 1, 0, 0, 0,
0, 0, 0, 0, 0, 0, 'português'], [3.3333333333333335, 0, 7, 2, 0, 0, 0, 1, 0, 1,
0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 6, 13, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 'inglês'], [8.2,
2, 18, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 5, 23, 0, 0, 0, 0, 0, 0,
0, 0, 0, 0, 'português'], [5.0, 3, 11, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0,
0, 0, 5, 14, 0, 0, 0, 0, 0, 0, 0, 0, 'português'], [4.25, 0, 7, 0, 0, 0, 0,
0, 1, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 4, 10, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 'inglê
s'], [4.375, 0, 18, 0, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 8, 17, 0, 0,
0, 0, 0, 0, 0, 0, 0, 0, 'português'], [4.75, 0, 8, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0,
0, 0, 0, 0, 0, 0, 0, 4, 11, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'espanhol'], [6.5, 0, 5,
0, 0, 0, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0, 2, 7, 0, 0, 0, 0, 0, 0, 0, 0, 0,
0, 'espanhol'], [4.5, 0, 8, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 4, 1
0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'espanhol'], [3.2, 0, 8, 0, 0, 0, 0, 0, 0, 0, 0,
0, 0, 0, 0, 0, 0, 0, 5, 8, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'espanhol'], [3.5, 0,
7, 0, 0, 0, 0, 0, 1, 0, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 4, 7, 0, 0, 0, 1, 0, 0, 1, 0,
0, 0, 'inglês'], [3.0, 0, 8, 0, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 6, 1
0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'inglês'], [5.0, 1, 11, 0, 0, 0, 0, 0, 0, 0, 0, 0,
0, 0, 0, 0, 0, 0, 5, 14, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'espanhol'], [3.4,
2, 7, 0, 0, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0, 0, 5, 7, 0, 0, 0, 0, 0, 0, 0,
0, 0, 0, 'português'], [3.8333333333333335, 0, 11, 0, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0,
0, 0, 0, 0, 0, 6, 12, 0, 0, 0, 0, 0, 0, 0, 0, 1, 0, 0, 'inglês'], [3.571428571428
5716, 0, 10, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, 0, 7, 15, 0, 0, 1, 0,
0, 0, 0, 1, 0, 0, 'inglês'], [4.625, 1, 19, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 1,
0, 0, 0, 0, 8, 18, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'português'], [5.2, 2, 12, 0, 0,
0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 5, 14, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'p
ortuguês'], [4.6, 1, 10, 0, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, 5, 13,
0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'espanhol'], [4.5, 0, 15, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0,
0, 0, 0, 0, 0, 0, 8, 21, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'português'], [2.333
33333333333335, 0, 5, 0, 0, 0, 0, 0, 1, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 6, 9, 0, 0,
0, 0, 0, 0, 0, 0, 0, 0, 'inglês'], [3.5, 0, 9, 1, 0, 0, 1, 0, 0, 1, 0, 0, 1, 0, 0, 1, 0,
0, 0, 0, 0, 6, 12, 0, 0, 1, 0, 0, 0, 0, 1, 0, 0, 'inglês'], [3.714285714285714
4, 2, 15, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 7, 11, 0, 0, 0, 0, 0, 0,
0, 0, 0, 0, 0, 'português'], [4.6, 1, 11, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0,
0, 0, 5, 12, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'português'], [3.25, 0, 6, 0, 0, 0,
0, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 4, 7, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'inglê
s'], [7.0, 0, 9, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 3, 12, 0, 0, 0,
1, 0, 0, 0, 0, 0, 0, 0, 'espanhol'], [3.8333333333333335, 1, 11, 0, 0, 0, 0, 0, 0,
0, 0, 0, 0, 0, 0, 0, 0, 6, 12, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'espanhol'],
[3.5714285714285716, 0, 10, 1, 0, 0, 0, 0, 0, 0, 1, 0, 0, 1, 0, 0, 0, 0, 0, 0, 7, 1
5, 0, 0, 1, 0, 0, 0, 0, 1, 0, 0, 'inglês'], [3.857142857142857, 0, 11, 1, 0, 0,
0, 0, 0, 1, 0, 0, 1, 0, 0, 0, 0, 0, 7, 16, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 'inglê
s'], [3.0, 0, 5, 0, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0, 0, 1, 0, 0, 4, 7, 0, 0, 0,
0, 0, 0, 0, 0, 0, 0, 0, 'inglês'], [4.75, 2, 11, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0,
0, 0, 0, 4, 8, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'português'], [4.5, 1, 13, 0, 0,
0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 6, 14, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0, 0, 'p
ortuguês'], [4.75, 0, 7, 0, 0, 0, 0, 0, 0, 0, 2, 0, 0, 0, 0, 0, 0, 0, 0, 0, 4, 12,
0, 0, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'inglês'], [5.166666666666667, 1, 14, 0, 0, 0, 0,
0, 0, 0, 0, 0, 0, 0, 0, 0, 6, 17, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'portugu
ês'], [4.6, 0, 10, 0, 0, 0, 0, 0, 1, 0, 1, 0, 0, 0, 0, 0, 0, 1, 0, 0, 5, 13, 0, 0,
0, 0, 0, 0, 0, 0, 0, 0, 'inglês'], [3.6, 0, 8, 0, 0, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 0,
0, 0, 0, 1, 5, 10, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'espanhol'], [4.0, 0, 6, 1,
0, 0, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 1, 0, 0, 4, 10, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0,
0, 'inglês'], [7.0, 0, 13, 0, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0, 0, 4, 15, 0,
0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'espanhol'], [4.2, 0, 9, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 0,
0, 0, 0, 0, 0, 5, 12, 0, 0, 1, 0, 0, 0, 0, 1, 0, 0, 'inglês'], [4.571428571428
571, 0, 14, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 7, 18, 0, 0, 0, 0, 0, 0,
0, 0, 0, 0, 0, 'português'], [4.833333333333333, 0, 14, 0, 0, 0, 0, 0, 0, 0, 1, 0,
0, 0, 1, 0, 0, 0, 0, 6, 15, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'espanhol'], [5.8333
333333333333, 0, 15, 0, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 6, 20, 0, 0,
0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 'português'], [3.7142857142857144, 0, 12, 0, 0, 0, 0, 0,

```



```
[1, 0, 0, 0, 0, 0, 'português'], [6.25, 0, 11, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0], [0, 0, 0, 4, 14, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0], [7.8, 1, 18, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0], [4.2, 1, 11, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0], [3.142857142857143, 1, 10, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0], [6.0, 1, 14, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0], [3.3333333333333335, 0, 8, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0], [4.2, 0, 10, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0], [4.25, 2, 7, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0]]
```

Out[4]:

	0	1	2	3	4	5	6	7	8	9	...	22	23	24	25	26	27	28	29	30
0	5.000000	1	13	0	0	0	0	0	0	0	...	0	0	0	0	0	0	0	0	0
1	3.333333	0	7	2	0	0	0	1	0	1	...	0	0	0	0	0	1	0	0	0
2	8.200000	2	18	0	0	0	0	0	0	0	...	0	0	0	0	0	0	0	0	0
3	5.000000	3	11	0	0	0	0	0	0	0	...	0	0	0	0	0	0	0	0	0
4	4.250000	0	7	0	0	0	0	0	1	1	...	0	0	0	0	0	1	0	0	0
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
87	3.142857	1	10	0	0	0	0	0	0	0	...	0	0	0	0	0	0	0	1	0
88	6.000000	1	14	0	0	0	0	0	0	1	...	0	0	0	0	1	0	0	0	0
89	3.333333	0	8	0	0	0	0	0	0	0	...	0	0	0	0	0	0	0	0	0
90	4.200000	0	10	0	0	0	0	0	0	0	...	0	0	0	0	0	0	0	0	0
91	4.250000	2	7	0	0	0	0	0	0	0	...	0	0	0	0	0	0	0	0	0

92 rows × 32 columns

Treinando o modelo com SVM

Separando o conjunto de treinamento do conjunto de testes

```
In [5]: from sklearn.model_selection import train_test_split
import numpy as np
from sklearn.preprocessing import StandardScaler

#from sklearn.metrics import confusion_matrix

vet = np.array(padroes)
classes = vet[:, -1]          # classes = [p[-1] for p in padroes]
#print(classes)
padroes_sem_classe = vet[:, 0:-1]
#print(padroes_sem_classe)
X_train, X_test, y_train, y_test = train_test_split(
    padroes_sem_classe,
    classes,
    test_size=0.25,
```

```

        stratify=classes,
        random_state=42
    )

    from sklearn.preprocessing import StandardScaler

    # Cria o normalizador
    scaler = StandardScaler()

    # Aprende a escala usando apenas o conjunto de treino
    X_train = scaler.fit_transform(X_train)

    # Aplica a mesma escala ao conjunto de teste
    X_test = scaler.transform(X_test)

```

Com os conjuntos separados, podemos "treinar" o modelo usando a SVM.

```

In [6]: from sklearn import svm
        from sklearn.metrics import confusion_matrix
        from sklearn.metrics import classification_report

        treinador = svm.SVC() #algoritmo escolhido
        modelo = treinador.fit(X_train, y_train)

        #
        # score com os dados de treinamento
        acuracia = modelo.score(X_train, y_train)
        print("Acurácia nos dados de treinamento: {:.2f}%".format(acuracia * 100))

        #
        # melhor avaliar com a matriz de confusão
        y_pred = modelo.predict(X_train)
        cm = confusion_matrix(y_train, y_pred)
        print(cm)
        print(classification_report(y_train, y_pred))

        #
        # com dados de teste que não foram usados no treinamento
        print('métricas mais confiáveis')
        y_pred2 = modelo.predict(X_test)
        cm = confusion_matrix(y_test, y_pred2)
        print(cm)
        print(classification_report(y_test, y_pred2))

```

Acurácia nos dados de treinamento: 89.86%

```
[[20 0 2]
 [ 1 22 0]
 [ 4 0 20]]
```

	precision	recall	f1-score	support
espanhol	0.80	0.91	0.85	22
inglês	1.00	0.96	0.98	23
português	0.91	0.83	0.87	24
accuracy			0.90	69
macro avg	0.90	0.90	0.90	69
weighted avg	0.90	0.90	0.90	69

métricas mais confiáveis

```
[[5 1 2]
 [0 7 0]
 [1 1 6]]
```

	precision	recall	f1-score	support
espanhol	0.83	0.62	0.71	8
inglês	0.78	1.00	0.88	7
português	0.75	0.75	0.75	8
accuracy			0.78	23
macro avg	0.79	0.79	0.78	23
weighted avg	0.79	0.78	0.78	23

Construção de Características

Foram utilizadas características relacionadas à presença de acentos, vogais, sequências de letras e palavras frequentes em cada idioma.

Características como "th" ajudam a identificar o inglês, "ñ" o espanhol e "ç", "nh" e "lh" o português.

Resultados

O modelo SVM obteve 78% de acurácia no conjunto de testes, superando a meta mínima de 70% estabelecida para o trabalho. Nos dados de treinamento, a acurácia atingiu entre 88% e 95%.

Observou-se que a construção dos atributos foi fundamental para a separação dos idiomas, validando a estratégia de engenharia de características.